SK AX AI Agent Capstone (MCP) · 최종 결과보고서

항공기 정비요청 Agent

정비 신고를 과거 이력과 SDR 사례로 분류하고 담당 부서에 배정하는 항공기 정비요청 Agent

소속	4기 판교 1반
팀	항공기 정비요청 Agent 팀
팀원	유영호 · 최세환 · 김유빈 · 곽나현 · 이주영 · 김경
작성일	2026-10-21 · 개정 2026-10-26
검토 기준	코드 10/26 · 서비스 평가 10/23

목차

1 프로젝트 배경, 목표 및 비즈니스 가치

2 시스템 아키텍처와 주요 설계

3 팀원별 역할 분담 및 주요 기능 구현

4 AI Agent, MCP, Harness 및 인증 구현

5 API 및 End-to-End 테스트 결과

6 주요 문제와 해결 방법, 미완성 기능 및 한계

자료 기준. 현재 구현은 2026-10-26 각 저장소 main을 기준으로 정리했다. 성능은 10/23 평가 200건, 기존 화면·S10 추적·인증·DLQ 기록은 10/21 자료다. 팀 라벨과의 일치율이며 실제 항공 정비 안전성이나 진단 정확도 지표는 아니다. 버전·출처는 6.4에 구분했다.

1. 프로젝트 배경, 목표 및 비즈니스 가치

1.1 배경

항공사 정비통제실에는 운항 중이나 지상에서 발견한 결함 신고가 계속 들어온다. 신고는 "상승 중 객실에서 퀴퀴한 냄새가 남"처럼 자연어로 들어오고, 어느 정비 부서가 맡을지는 통제 담당자가 경험으로 판단한다.

- 같은 기체에서 최근 반복된 결함인지 매번 이력을 찾아봐야 한다.
- 증상이 두 계통에 걸쳐 보이면 부서 판단이 사람마다 다르고, 잘못 배정되면 재배정까지 시간이 든다.
- 왜 그 부서로 보냈는지 근거가 기록으로 남지 않는다.

1.2 목표와 범위

신고가 들어오면 같은 기체의 수리이력과 유사 결함 사례(SDR)를 근거로 담당 부서를 정하고, 근거와 함께 배정한다. 근거가 부족하거나 판단이 엇갈리면 자동 배정을 멈추고 사람 검토로 넘긴다.

구분	내용
대상 기종	Airbus A320 계열 (목업 기체 20대, 항공사 3곳: KAL·AAR·JNA)
배정 단위	정비 부서 8개: AVI 항전, ELE 전기, ENG 엔진, HYD 유압·착륙장치, SYS 기계 계통, STR 구조, CAB 객실, FCS 비행 조종
범위 안	신고자 회원가입·로그인, 신고 접수와 보완 안내, 초기 분류, 근거 조사, 검토·배정, 정비팀 수락·거절, 사람 검토, 역할별 대시보드, 관리자 인원 현황 조회
범위 밖	실제 정비 절차 지시, 운항 가능 여부 판단, 정비팀 거절 후 자동 재배정

1.3 비즈니스 가치

대상은 항공사 정비본부와 MRO(정비 위탁) 업체의 정비통제 조직이다(B2B).

가치	내용
배정 시간 단축	반복 결함은 접수 단계에서 같은 기체 이력과 바로 연결해 조사 없이 배정한다.
근거가 남는 배정	배정에는 수리이력 또는 SDR 근거 ID와 원문 일부가 남는다. 근거 SDR에서 AMM 참조가 확인되면 참고번호와 맥락을 별도로 첨부한다.
책임 범위 구분	근거가 맞지 않거나 판단이 엇갈리는 건은 이유와 함께 사람에게 넘겨 자동화 범위를 통제한다.
확장성	부서·ATA 매핑과 RAG 데이터는 버전 단위로 바꿀 수 있어 다른 기종·조직에도 같은 구조를 쓸 수 있다.

서비스 평가 200건 (2026-10-23, 실제 `gpt-5.4-mini` · HTTP MCP · RabbitMQ · Docker Postgres). 수치는 기존 실행 자료를 재집계한 것이며 이번 문서 개정 중 새 평가를 실행하지 않았다.

전체 평가 통과	자동배정 중 통과	자동 배정률	평균 처리 시간
97/200	**66.21%**	**72.5%**	**21.94초**
48.5% · 팀 기대 라벨 기준	96/145건 · 실패 49건	145/200건 · 사람 검토 55건	P95 60.4초 · 접수 검증 별도 6/6

이 평가는 서비스 연결과 판단 결과를 함께 확인했다. LLM2·3 경로의 자동배정 29건은 모두 팀 채점 기준을 통과했지만, LLM1 직접 배정에는 실패 49건이 남았다. 자동화의 효과와 함께 직접 배정의 근거 검증을 보강해야 할 지점이 확인됐다.

2. 시스템 아키텍처와 주요 설계

2.1 전체 구성

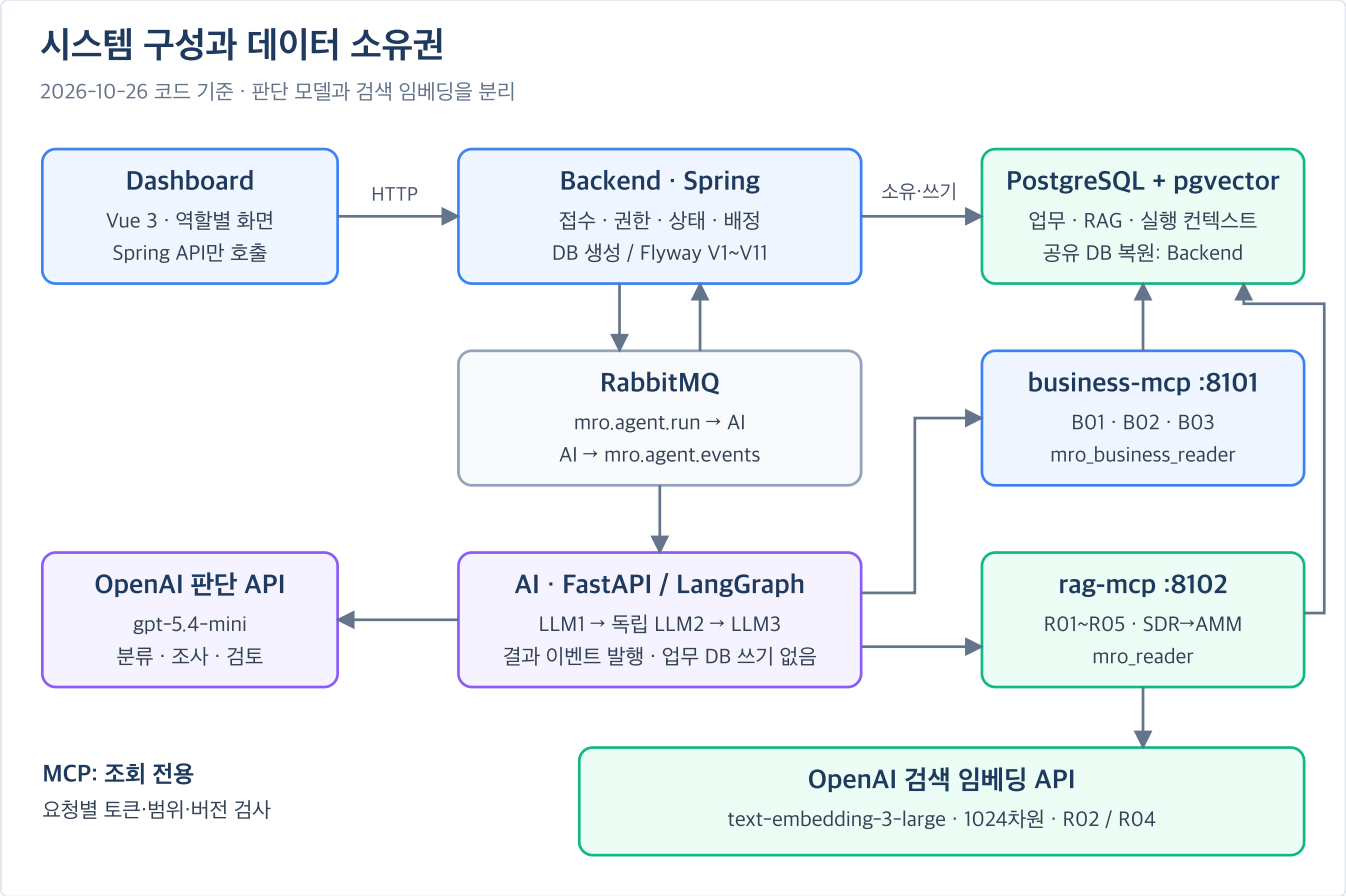


그림 2-1. 시스템 구성도 (2026-10-26 코드 기준). 판단 모델과 검색 임베딩 API를 구분했다.

구성 요소	포트	기술	역할
프론트엔드	5173	Vue 3.5, TypeScript, Vite 7, PrimeVue 4	신고자·정비팀·어드민 화면과 회원가입. Spring API만 호출
Backend	8080	Spring Boot 3.5, Java 21, Flyway	인증·권한, 접수 확인, 상태 관리, 근거 검증과 배정 실행, 실행별 검색 범위와 MCP 위임 토큰 발급
RabbitMQ	5672	RabbitMQ 4.1	실행 요청·결과 이벤트 전달, 실패 메시지 DLQ
AI 서버	8100	Python 3.12, FastAPI, LangGraph	큐에서 실행 요청을 받아 LLM1~3 실행, MCP 도구 호출, 결과 이벤트 발행
business-mcp	8101	FastMCP	접수 내용, 기체 수리이력, 부서 후보 조회 (B01~B03)
rag-mcp	8102	FastMCP, pgvector, OpenAI 임베딩 API	JASC·SDR·AMM·기술자료 검색, 근거 확인, SDR의 AMM 참고번호 조회
PostgreSQL	5432	PostgreSQL 16 + pgvector 0.8.2	업무 데이터, RAG 데이터와 임베딩, 실행별 검색 범위
LLM	-	OpenAI gpt-5.4-mini	분류·조사·검토 판단과 다음 도구 선택

2.2 핵심 처리 흐름

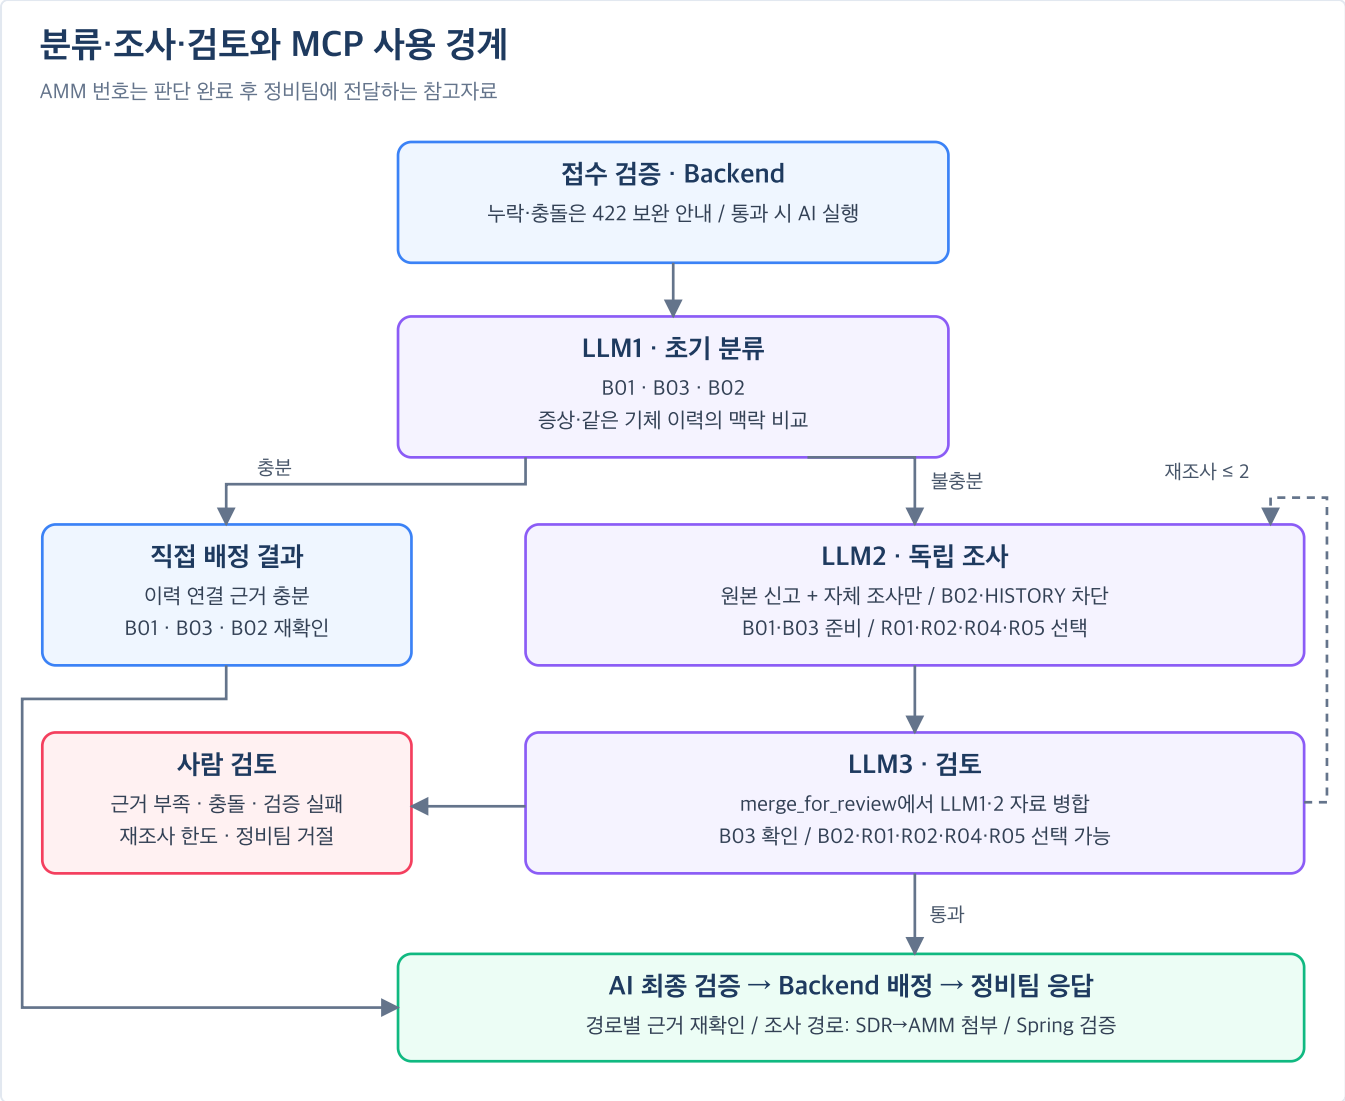


그림 2-2. 정비 요청 분류·배정 흐름과 LLM별 MCP 도구

1. 신고자가 요청을 보내면 Spring이 기체 마스터와 대조한다. 누락·충돌이면 아무것도 저장하지 않고 422(NEEDS_SUPPLEMENT)로 응답한다.
2. 통과하면 요청을 QUEUED로 저장하고 202를 돌려준다. 커밋 후 실행 ID를 새로 만들고, 검색 범위를 기록한 뒤 위임 토큰과 함께 실행 요청을 큐에 넣는다.
3. AI 서버가 LLM1로 초기 분류한다. 증상만 보고 계통(ATA)을 먼저 정하고, 그 계통의 같은 기체 이력으로 충분하면 바로 배정 결과를 만든다.
4. 부족하면 LLM2가 LLM1 판단·수리이력을 받지 않고 원본 신고와 RAG로 독립 조사한다. LLM3에서 두 결과를 합쳐 비교하며, 보완 시 최대 2회 독립 재조사한다. AMM은 판단 근거에서 제외하고 배정 결과의 참고자료로 첨부한다.
5. AI 서버는 근거 원문을 다시 확인한 뒤 결과 이벤트를 보내고, Spring이 근거 ID와 부서를 검증한 뒤 배정한다.
6. 정비팀이 수락하면 끝나고, 거절하면 사람 검토로 넘어간다. 통제사는 수동 배정하거나 종결한다.

상태	의미	다음 상태
QUEUED	접수 확인 통과, 실행 요청 발행	진행 중 상태끼리(QUEUED 제외), ASSIGNED, HUMAN_REVIEW
CLASSIFYING	LLM1 초기 분류 중	
INVESTIGATING	LLM2 조사 중	
REVIEWING	LLM3 검토 중	
ASSIGNED	부서 배정, 정비팀 응답 대기	ACCEPTED, HUMAN_REVIEW
HUMAN_REVIEW	사람 검토 대기, 자동 배정 중지	ASSIGNED, CLOSED
ACCEPTED · CLOSED	정비팀 수락 · 어드민 종결	종료

상태는 Spring의 RequestWorkflow로만 바뀌고, 허용되지 않은 전이는 409(INVALID_STATE)로 막는다. 사람 검토 사유: AGENT_NEEDS_HUMAN, RETRY_LIMIT, TEAM_REJECTED, VALIDATION_FAILED, SYSTEM_ERROR.

2.3 Agent 설계: State와 Graph

요청 하나를 처리하는 동안 노드들이 함께 쓰는 상태(GraphState)를 두고, 노드는 상태를 읽어 바뀐 필드만 돌려준다. 출력은 Pydantic 스키마로 검사하고, 형식 오류는 오류 내용을 알려 1회 다시 받는다. NextStep의 사용하지 않는 선택 필드 등 의미가 같은 빈 값은 정규화한다. LLM2는 공유 상태 전체가 아닌 InvestigatorState만 받는다.

필드	타입	채우는 곳과 의미
request_id 외 4개	str	실행 요청 메시지. 요청 ID, 등록부호, 정확한 모델, 항공사, 증상
classification	Classification | None	LLM1. ATA 2자리, 연결한 수리이력 ID, 충분 여부, 제안 부서(충분일 때 필수), 이유
investigations	list[Investigation]	LLM2. 재조사마다 쌓임. ATA, 추정 결함, 심각도(LOW·MEDIUM·HIGH·AOG), 근거(1개 이상), 제안 부서
reviews	list[Review]	LLM3. 결정(PASS·SUPPLEMENT·HUMAN), 부서(PASS일 때 필수), 의견, 보완 요청(SUPPLEMENT일 때 필수)
llm2_context	dict[str, Any] (선택)	LLM2 전용 도구 컨텍스트. 원본 요청과 자체 검색 결과만 유지하며 classification·HISTORY·검토 자유문장은 전달하지 않음
retry_count	int	라우팅. SUPPLEMENT로 LLM2에 되돌아간 횟수

근거(Evidence)는 출처, 근거 ID, 원문 일부(300자 이내), 사용 이유로 구성한다. Evidence.source는 HISTORY·SDR·AMM이다. LLM2는 HISTORY를 사용할 수 없고 AMM은 LLM2·3 판단 근거에서 제외한다. 기술자료는 별도의 TECHNICAL_DOC 조회 기록과 technical_basis_ids로 추적하며, 결론에 필수이면 적용성 확인을 위해 보류한다.

분기 조건	다음
classification.sufficient == True	바로 배정 결과
classification.sufficient == False	LLM2 조사·판정 → LLM3 검토
review.decision == "PASS"	근거 재확인 → 배정 결과
"SUPPLEMENT", retry_count < 2	LLM2 독립 재조사 (자체 조사 결과와 일반 재점검 지시만 전달)
"SUPPLEMENT", retry_count >= 2	사람 검토 (RETRY_LIMIT)
"HUMAN"	finalize에서 사람 검토 결과 구성 (AGENT_NEEDS_HUMAN)
내부 hold 있음	hold에서 사람 검토 결과 구성

Agentic 요소는 네 가지다. LLM2·LLM3가 매 단계 다음 행동(도구 호출·마무리·보류)과 도구를 스스로 고른다. LLM3가 두 판단의 근거·계통·부서와 기종 적용성을 대조한다. 재조사는 LLM1 결론이나 LLM3의 구체적 보완 문장을 LLM2에 노출하지 않도록 분리한다. 판정에는 도구 결과에 실제로 있던 근거만 쓴다. 근거가 맞지 않거나 한도를 넘으면 이유 코드와 함께 스스로 멈추고 사람에게 넘긴다.



그림 2-3. DB 테이블 → MCP 도구 → GraphState 필드 연결

2.4 기술 선택과 설계 근거

영역	선택	근거
Backend	Spring Boot 3.5, Spring Security(JWT), JPA, Flyway	권한, 상태 전이, 배정 같은 업무 규칙을 한 곳에 모은다. 스키마는 Flyway 이력(V1~V11)으로만 바꾼다.
AI 서버	FastAPI, LangGraph, LangChain MCP 어댑터	분기와 반복이 있는 흐름을 그래프로 표현하고, 요청 단위로 상태를 체크포인트에 저장한다.
서버 간 통신	RabbitMQ 4.1 + DLQ	LLM 처리는 수 초~수십 초가 걸려 HTTP 동기 호출 대신 큐로 분리했다.
MCP	FastMCP 서버 2개, streamable HTTP	업무 조회와 근거 검색을 표준 도구로 노출하고, 인증·응답 형식·읽기 전용 DB를 공통 기반으로 쓴다.
DB	PostgreSQL 16 + pgvector	업무 데이터와 벡터 검색을 DB 하나에서 스키마와 조회 계정으로 나눠 운영한다.
임베딩	text-embedding-3-large (1024차원)	R02 SDR·R04 기술자료 검색에 사용한다. 질의 임베딩은 OpenAI API를 호출하며 비용·지연이 발생한다. 현재 런타임에는 PyTorch·로컬 모델이 없다. 이전 e5 제작 파이프라인과 구분한다.

영역	선택	근거
LLM	OpenAI gpt-5.4-mini	처음에는 비용이 낮은 gpt-4o-mini로 시작했으나, 실제 실행에서 무관한 이력 연결·조기 종료가 잦아 같은 소형 계열의 상위 모델로 바꿨다. AI 서버가 허용 목록(gpt-4o-mini·gpt-4.1-mini·gpt-5.4-mini)으로 교체를 지원한다.

2.5 품질 특성 대응 (ISO/IEC 25010)

품질 특성	설계 대응
기능 적합성	상태 전이 규칙을 Spring 한 곳에서 검증. 배정 직전에 부서 활성 여부와 근거 ID를 다시 확인
성능 효율성	접수는 202로 바로 응답하고 AI 처리는 큐로 비동기 실행. MCP 문장 8초, AI 측 도구 10초·모델 45초 제한. 실측 평균 21.94초
호환성	MCP 표준 도구와 공통 응답 형식. 서버 간 메시지는 JSON(snake_case), 시간은 UTC
사용성	필드 단위 보완 안내(422)와 등록 정보 한 번에 적용, 진행 상태 폴링(3초), 단계별 판단과 근거 화면
신뢰성	결과 이벤트 확인 후 ack, 실패 시 재전달, 처리 불가 메시지는 DLQ, 5분 시간 초과는 사람 검토, event_id로 중복 제거
보안	JWT와 행 단위 권한(남의 요청은 404). MCP는 실행별 위임 토큰으로만 호출, 서버별 조회 전용 계정과 전용 뷰 권한, 쓰기 도구 없음
유지보수성	인터페이스 규약으로 모듈 경계 고정, Flyway 스키마 이력, RAG 데이터는 버전 덤프로 교체
이식성	docker compose로 DB·큐·Backend·데이터 복원을 함께 실행. MCP·AI 서버도 각자 Dockerfile과 compose 제공

2.6 레퍼런스 아키텍처와 다른 점

강의 레퍼런스 아키텍처는 business-mcp가 Spring 내부 API(`/internal/**`)를 거치도록 정한다. 우리 구현은 business-mcp가 조회 전용 계정(`mro_business_reader`)으로 DB를 직접 읽고, Spring에는 `/internal/**` 경로가 없다. 업무 규칙이 MCP로 새지 않도록 다음 장치를 두었다.

- 조회 전용 계정에 필요한 테이블과 `agent_request_context`·`agent_run_context` 뷰만 연다. V9에서 V6의 `repair_requests` 직접 열 권한을 회수했고 신고자 식별 정보는 공개하지 않는다.
- 도구 호출은 읽기 전용 트랜잭션에서만 실행하고, 서버 시작 시 쓰기 권한이 있는 계정이면 실행을 거부한다.
- 모든 호출에 실행별 위임 토큰이 필요하고, 토큰의 요청 ID와 다른 요청은 조회할 수 없다. 상태 변경과 배정은 Spring만 한다.

결정 · 유지. MCP 도구는 모두 조회 전용이라 Spring을 거쳐도 얻는 업무 규칙 보호가 없고, 오히려 Spring에 도구별 내부 API와 응답 변환이 생긴다. 대신 전용 뷰 권한(V9), 읽기 전용 트랜잭션, 실행별 위임 토큰과 요청 ID 대조로 같은 경계를 지켰고, 실제 실행에서 토큰 없는 호출 401·다른 요청 조회 FORBIDDEN을 확인했다(4.4).

3. 팀원별 역할 분담 및 주요 기능 구현

3.1 역할 분담

팀원	담당	주요 구현 결과	저장소
유영호	Backend, 통합, 권한 관리	인증·회원가입, 접수 확인(422), 상태 머신, RabbitMQ·DLQ, 근거 검증과 배정 실행, 실행별 검색 범위와 MCP 위임 토큰, Flyway V1~V11, 데이터 복원 스크립트, 대시보드 백엔드 연동, CI, 전체 종단 간 통합	backend, dashboard
최세환	SDR·AMM DB, rag-mcp, AI 실행기	SDR·AMM·JASC 정제와 적재, SDR 임베딩·하이브리드 검색과 RAG MCP 연결, RAG 데이터 덤프 전달, LLM1과 FastAPI·RabbitMQ 실행기, LLM2·LLM3 통합	agent, llm
김유빈	LLM2·LLM3	조사·판정(LLM2)과 검토·배정(LLM3) 노드, 도구 선택 반복, 근거 검증, MCP 계약 맞춤	llm
곽나현	MCP 도구와 클라이언트 연결	FastMCP 공통 기반(인증·응답 형식·읽기 전용 DB), business-mcp(B01~B03), rag-mcp 공통 기반 전환	agent
이주영	대시보드, 사용자 데이터	신고자·정비팀·어드민 대시보드 화면 구성, 사용자 시드 데이터	dashboard
김경	목업 데이터, 기술자료	수리이력 목업과 테스트 시나리오 29건, Safety First 기술자료 61편 정제·임베딩과 V5 테이블, 흐름도·구성도	backend(seed, V5)

통합 단계(10/21)의 변경 이력 · 아래 표는 당시 조치이며 현재 구현은 2·4장과 구분한다.

저장소	변경
backend	신고자 회원가입·항공사 목록 API, FCS(ATA 27) 부서·계정·수리이력 78건·시나리오 S23, 기술자료 부서 매핑 재계산, Flyway V6, 실행별 검색 범위와 MCP 토큰 발급, VALIDATION_FAILED 사유 보존
dashboard	목업 제거와 실제 API 연결, 로그인·회원가입 화면, 전체 화면 디자인 개편(항공기 정비요청 Agent 로고)
agent	business-mcp 토큰 검증, 기종 기준 검색 범위, 넓은 검색의 단어 순위 검색, 도구 설명 보강, CPU 전용 PyTorch(이미지 19.3GB → 2GB)
llm	LLM1 2단계 분류와 연결 이력 검증, LLM2 근거 확보 장치, 모델 입력 축약, 형식 오류 재시도, gpt-5.4-mini 지원, Dockerfile 기본 이미지 수정

3.2 역할별 화면

화면	주요 기능
로그인·회원가입	신고자는 이름, 이메일, 소속 항공사, 비밀번호로 가입하고 바로 로그인. 역할에 따라 각자의 화면으로 이동
신고자	수리 요청 작성(등록부호·모델·항공사·증상), 422 보완 안내와 등록 정보 적용, 내 요청 목록과 검색, 진행 단계 표시(처리 중이면 3초마다 갱신)
정비팀	내 부서 배정 대기함(15초마다 갱신), 대기·수락·거절 건수, 수락, 사유를 적는 거절, AI 판단 근거 보기
어드민(통제사)	전체 요청과 사람 검토 우선 정렬, 통계(전체, 사람 검토, 자동 배정률, 첫 배정까지 평균 시간), RAG 데이터 상태, 수동 배정·종결, 인원 현황(/admin/staffing)
판단 근거	단계별 AI 판단, ATA, 제안 부서, 재조사 횟수, 판단 근거와 참고 AMM을 나눈 패널, 상태 이력. 수동 배정이 AI 제안과 다르면 표시

아래 화면은 2026-10-21 촬영본이다. 현재 인원 현황(38명·8부서, 15초 갱신), 어드민 진입 버튼, 참고 AMM 분리 패널은 코드로 확인했다. 최신 화면 재촬영은 실행 환경 기동 후 필요하다. 인원 수는 조회용이며 자동 배정이나 개인 담당자 지정에 반영되지 않는다.

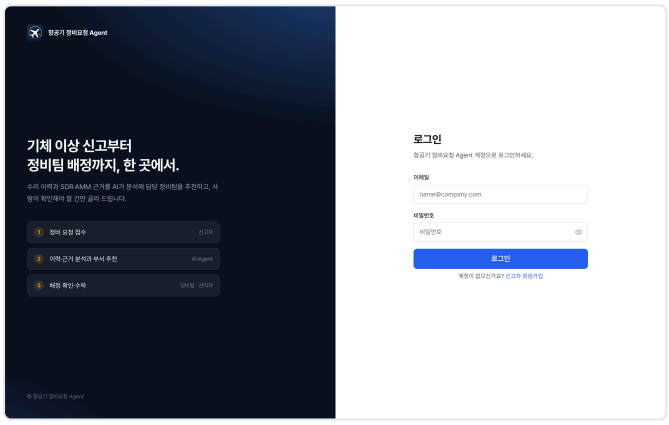


그림 3-1. 로그인

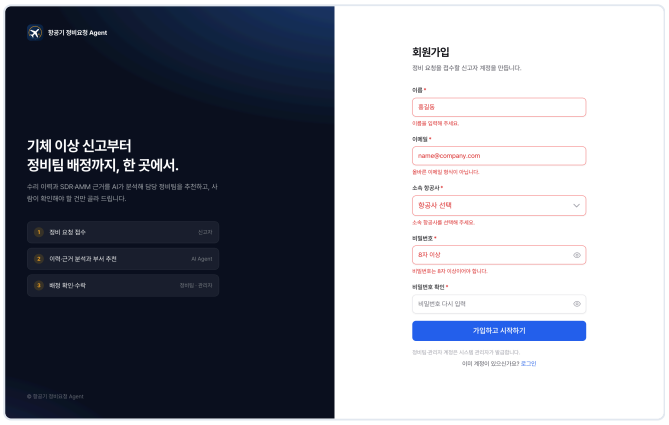


그림 3-2. 신고자 회원가입 (입력 검증)

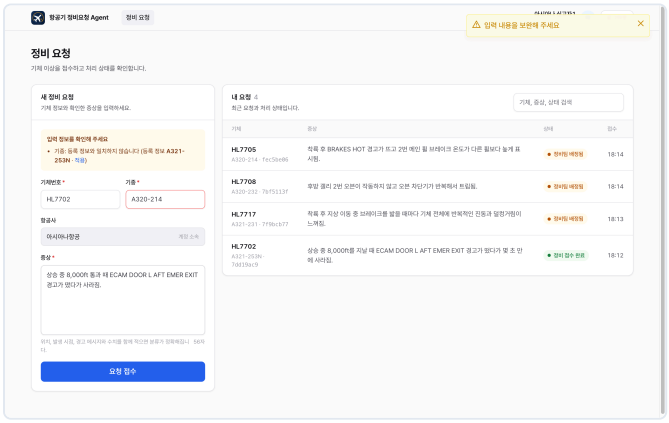


그림 3-3. 신고자 접수와 422 보완 안내 (등록 정보 A321-253N 적용)

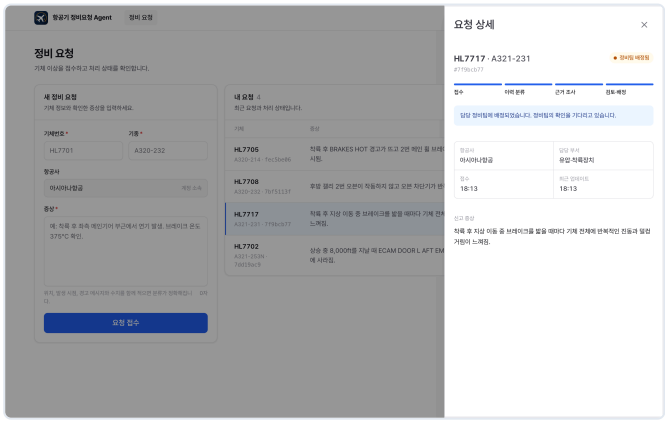


그림 3-4. 신고자 요청 상세와 진행 단계 (S10, 조사 경로 완료 후 배정)

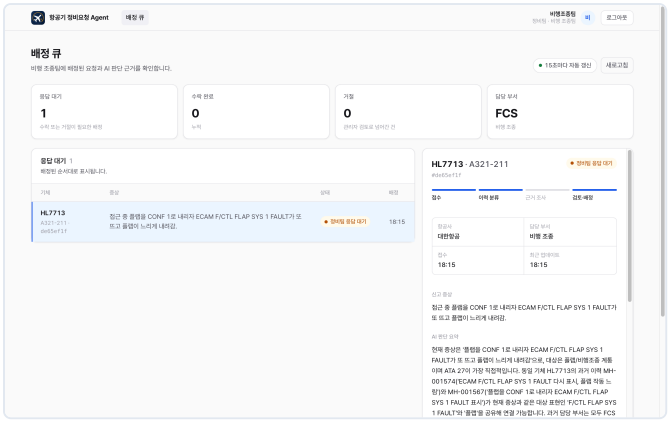


그림 3-5. 정비팀 배정 대기함 (FCS, S23 반복 결함 바로 배정)

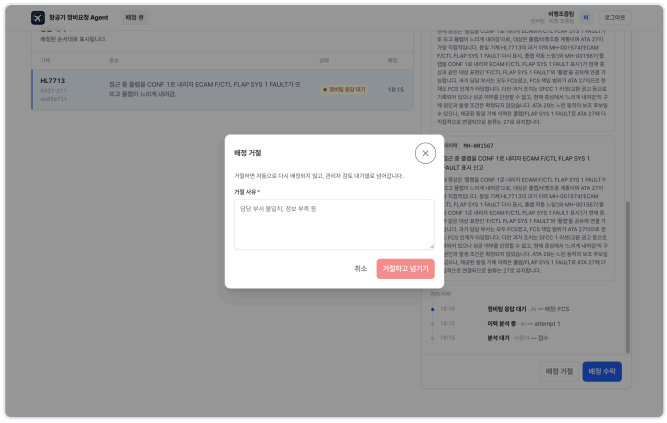


그림 3-6. 정비팀 배정 거절 (사유 필수, 사람 검토로 전환)

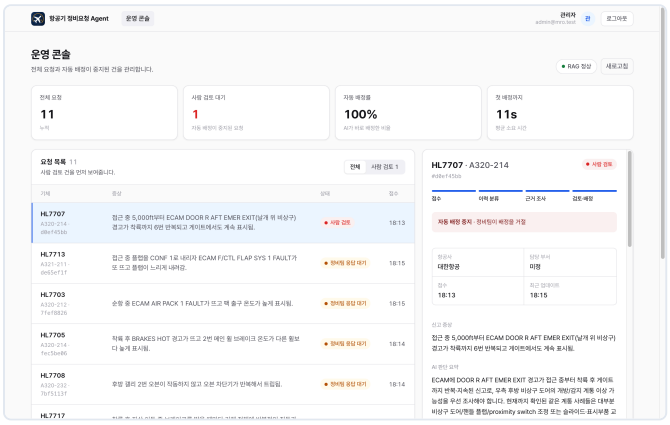


그림 3-7. 어드민 운영 콘솔과 통계 (시연 데이터 11건 기준)

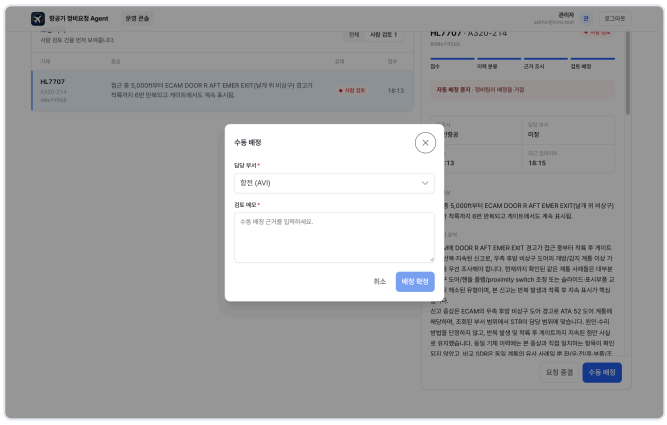


그림 3-8. 사람 검토(정비팀 거절) 건의 수동 배정

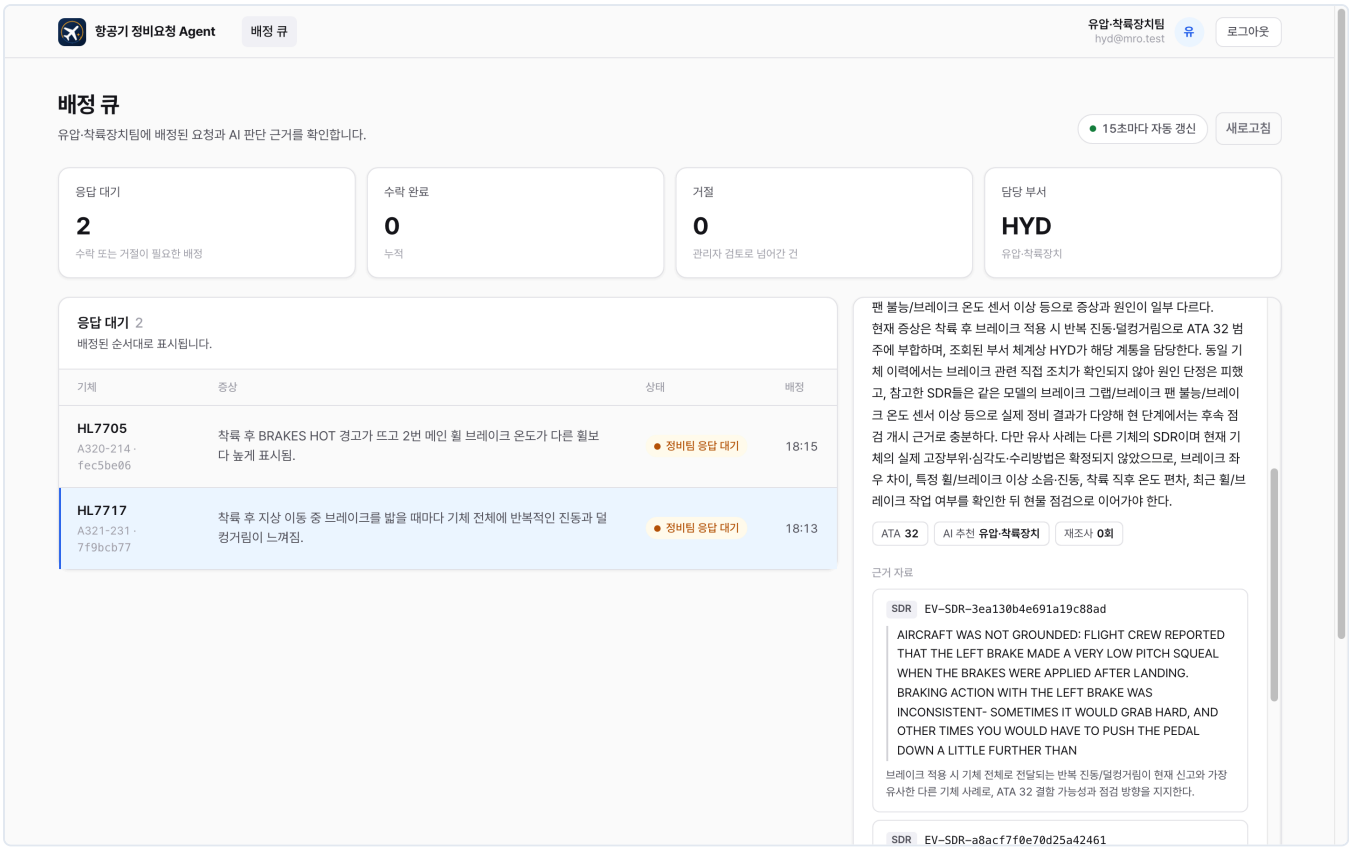


그림 3-9. 판단 근거 화면: S10 브레이크 진동 → ATA 32, HYD. LLM2가 찾은 SDR 사례("REPEATED VIBRATION AND THUMPING … EACH TIME THE BRAKES WERE APPLIED")가 근거로 표시된다.

3.3 데이터 구성

데이터	규모	출처와 의미
기체·항공사	20대 · 3곳	목업. KAL·AAR·JNA, A320 계열의 정확한 세부 모델 사용
수리이력	1,600건	현재 maintenance_history_v2.csv 시드. SDR 기반 목업, JASC 코드 포함
부서·정비 인원	8개 · 38명	부서별 ATA 매핑, technicians 시드. 인원 현황 조회용
계정	15개 + 가입	어드민 1, 신고자 6, 정비팀 8 시드. 신고자 회원가입 지원
SDR 사례·임베딩	각 71,741건	FAA SDR, text-embedding-3-large 1024차원. 원본 필드·근거 연결 보존
AMM 인용	35,396건	SDR에 나온 참조번호·인용 맥락. 실제 매뉴얼 본문이나 정비 절차가 아님
JASC·근거	548개 · 107,137건	분류 코드와 SDR·AMM 근거 ID. 파생 근거는 evidence_group_id로 묶음
기술자료	61편 · 496조각	Airbus Safety First. R04 검색 구현, 정비 적용성 확인 대상 문서로 범위 제한

업무 규모는 현재 CSV, RAG 규모는 10/23 실행 검증 기록 기준이다. 이번 문서 개정에서 DB를 새로 기동·집계하지 않았다. V7은 SDR 임베딩, V8은 기술자료 1024차원 전환과 AMM 의미검색 테이블 제거, V9는 업무 조회 뷰, V10은 인원 현황, V11은 모델 검색 범위를 관리한다.

공유 DB의 생성·마이그레이션·시드·덤프 복원은 Backend가 소유한다. 기본 SDR·JASC·AMM 데이터 전용 덤프(6개 테이블)와 별도 임베딩·기술자료 전달본을 스키마 버전에 맞춰 복원하며 MCP는 조회 계정만 사용한다. 기존 볼륨을 문서 작업 중 덮어쓰지 않았다.

4. AI Agent, MCP, Harness 및 인증 구현

4.1 AI Agent 구현

위치 (llm 저장소)	내용
`app/agent/full_workflow.py`	LLM1→2→3 전체 그래프와 분기 함수. 재조사 한도 2, 재귀 한도 80
`app/agent/nodes/`	`classify.py`(LLM1), `investigate.py`(LLM2), `review.py`(LLM3), `common.py`(준비 단계와 근거 선택 반복, 모델 입력 축약)
`app/agent/tools.py`	도구 호출 관문: 허용 목록, 입력 검증, 노드당 호출 8회 한도, 근거 원문 대조
`app/server/`	RabbitMQ 실행기, 이벤트 저널(SQLite), 위임 토큰 처리

- **LLM1:** B01 접수 내용 → B03 부서 → B02 같은 기체 이력을 준비한다. 증상만으로 ATA 후보를 고르고 해당 이력을 비교한다. 현재 증상·이력의 원문을 각각 인용하고 대상·현상 관계, PRESENT/ABSENT, 중요 충돌을 구조화한다. 코드가 인용과 관계·ATA·부서 조건을 검사하며, 공통 키워드나 30일·2건만으로 충분 판정을 고정하지 않는다. 의미 관계 자체는 모델의 판단이다.
- **LLM2:** InvestigatorState와 llm2_context로 격리한다. 원본 요청·자체 조사·검색 결과만 보고, LLM1 classification·수리이력·검토 자유문장·공개 단계 이벤트는 받지 않는다. B02 호출과 HISTORY 인용을 차단한다.
- **LLM3:** merge_for_review가 요청·버전·범위·스냅샷을 검사한 뒤 LLM1·2 자료를 합친다. 검토자는 추가 B02 조회가 가능하다. 미해결 판단 충돌, B03의 ATA·부서 일치, 비교 근거 인용, 확장 기종의 구성 차이를 확인한다.
- **상태 저장:** 요청 단위 체크포인트와 이벤트 저널로 재개·최종 이벤트 재발행을 지원한다. 전체 그래프 thread ID는 `llm123-isolated-v2:{request_id}`다.
- **진행 이벤트:** STAGE_STARTED, STAGE_RESULT, COMPLETED, FAILED. Spring은 단계 결과와 상태를 저장하고 권한 있는 정비팀·어드민에 trace API로 제공한다.

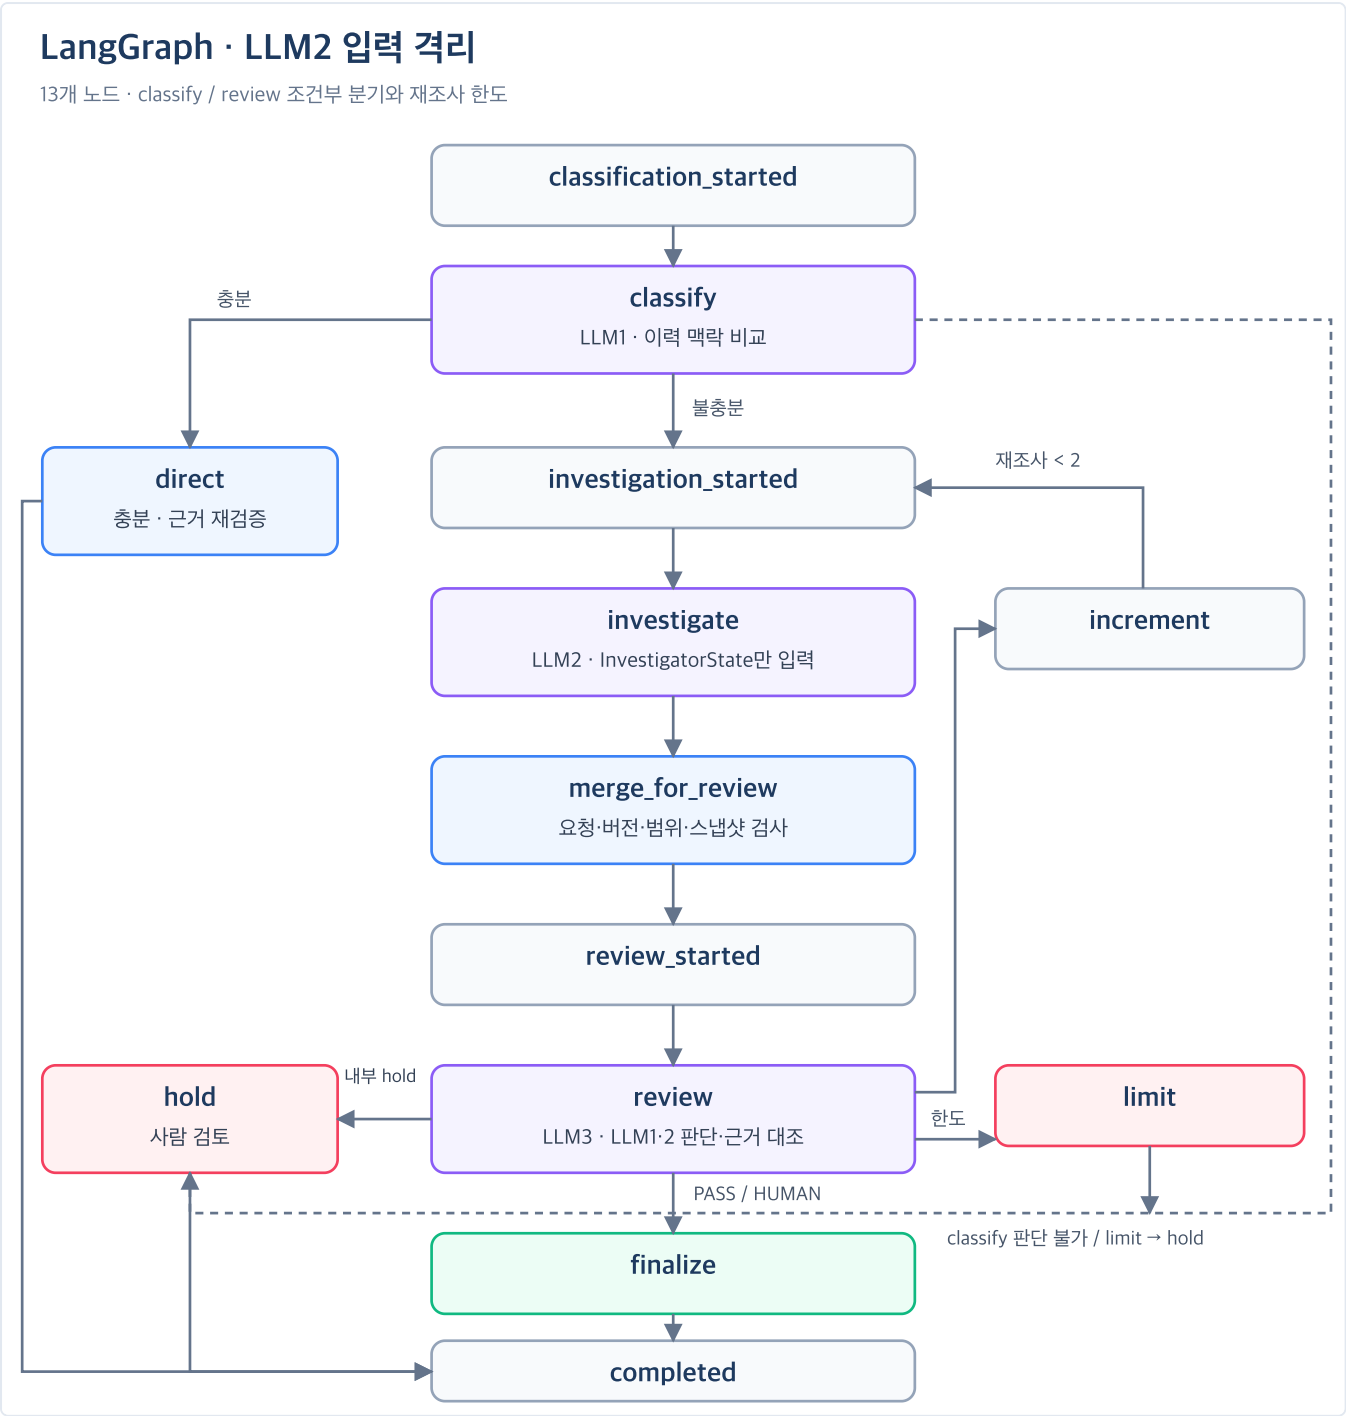


그림 4-1. 현재 LangGraph 노드와 분기. LLM2의 입력 경계와 검토 전 병합을 표시했다.

아래 S10은 2026-10-21의 과거 실행 기록이다. 10/23 평가나 현재 LLM2 격리 구조의 예시로 사용하지 않는다. 원본 추적·화면·결과 JSON을 보존해 당시 도구 호출을 확인할 수 있게 했다.

과거 실행 기록: S10 (이력 없는 신규 증상 → 조사 경로)

입력: HL7717 / A321-231 / AAR, "착륙 후 지상 이동 중 브레이크를 밟을 때마다 기체 전체에 반복적인 진동과 덜컹거림이 느껴짐." (실제 gpt-5.4-mini, business-mcp·rag-mcp, 위임 토큰 사용)

순서	단계	종류	도구 / 이벤트	입력 요약	결과
1	LLM1 분류	이벤트	STAGE_STARTED	-	-
2	LLM1 분류	MCP 호출	get_request_context	{}	OK
3	LLM1 분류	MCP 호출	search_departments	{"limit": 20}	OK
4	LLM1 분류	MCP 호출	get_aircraft_history	{"limit": 100}	OK, 83건 (MH-001497, MH-001485, MH-001436)
5	LLM1 분류	이벤트	STAGE_RESULT	-	ATA 32, 연결 이력 0건, sufficient=False → 조사로
6	LLM2 조사	이벤트	STAGE_STARTED	-	-
7	LLM2 조사	MCP 호출	get_request_context	{}	OK
8	LLM2 조사	MCP 호출	search_departments	{"query": "착륙 후 지상 이동 중 브레이크를 밟을 때마다 기체 전체에 반복…	OK
9	LLM2 조사	AI 판단	NextStep: FINISH	현재 신고 증상은 ATA 32(착륙장치/브레이크) 계통으로 볼 수 있는가, 그리고 …	조사 종료 요청 → 근거 없음으로 반려 (FINISH_WITHOUT_EVIDENCE)
10	LLM2 조사	AI 판단	NextStep: CALL → search_sdr_cases	브레이크 사용 시 지상 활주 중 반복 진동/덜컹거림과 가장 유사한 SDR 사례가 있…	도구 선택
11	LLM2 조사	MCP 호출	search_sdr_cases	{"query": "brake vibration taxi", "search_mode…	OK, 5건 (EV-SDR-ecdb00b3c949d4bc6ccd, EV-SDR-44c7c329863866bf6fa1, EV-SDR-dcf9ab1ad7ab73b11c9c)
12	LLM2 조사	AI 판단	NextStep: FINISH	현재 증상은 ATA 32(유압·착륙장치)로 충분히 분류 가능한가, 그리고 브레이크 …	조사 종료 요청
13	LLM2 조사	이벤트	STAGE_RESULT	-	ATA 32, 심각도 MEDIUM, 제안 HYD, 근거 EV-SDR-3ea130b4e691a19c88ad, EV-SDR-a8acf7f0e70d25a42461
14	LLM3 검토	이벤트	STAGE_STARTED	-	-
15	LLM3 검토	MCP 호출	get_request_context	{}	OK
16	LLM3 검토	MCP 호출	search_departments	{"query": "착륙 후 지상 이동 중 브레이크를 밟을 때마다 기체 전체에 반복…	OK
17	LLM3 검토	AI 판단	NextStep: FINISH	브레이크 적용 시 택싱 중 반복 진동·덜컹거림 증상이 HYD(ATA 32/29) 후…	조사 종료 요청
18	LLM3 검토	이벤트	STAGE_RESULT	-	PASS → HYD
19	최종 재검증	MCP 호출	get_request_context	{}	OK
20	최종 재검증	MCP 호출	search_departments	{"query": "착륙 후 지상 이동 중 브레이크를 밟을 때마다 기체 전체에 반복…	OK
21	최종 재검증	MCP 호출	get_evidence	{"evidence_id": "EV-SDR-3ea130b4e691a19c88ad"}	OK, 1건 (EV-SDR-3ea130b4e691a19c88ad)
22	최종 재검증	MCP 호출	get_evidence	{"evidence_id": "EV-SDR-a8acf7f0e70d25a42461"}	OK, 1건 (EV-SDR-a8acf7f0e70d25a42461)
23	완료	이벤트	COMPLETED	-	ASSIGN → HYD

LLM1은 같은 기체 이력 83건 가운데 브레이크(ATA 32) 이력이 없어 연결하지 않았다. LLM2는 처음 근거 없이 마무리하려다 반려된 뒤 `search_sdr_cases`를 영어 핵심어 `brake vibration taxi`로 호출해 SDR 5건을 찾았고, 그중 2건으로 조사안을 썼다. LLM3가 PASS한 뒤 최종 재검증에서 `get_evidence`(R05)로 두 근거의 원문을 다시 확인하고 HYD 배정 이벤트를 보냈다.

당시 구조화 출력 원문: raw/trace_final.html. 현재 형식과 혼동하지 않도록 원문은 별도 보존한다.

4.2 MCP 구현

ID	도구	현재 동작·사용 주체
B01	`get_request_context`	전용 요청·실행 뷰에서 접수와 실제 run의 검색 범위·버전을 읽음. 실행기 준비·최종 검증, LLM2 독립 컨텍스트 구성에 사용. 기체 마스터 접수 검증은 Backend 역할
B02	`get_aircraft_history`	같은 기체의 신고 시각 이전 이력, 최신순·커서. LLM1·LLM3·최종 검증에 허용, LLM2는 차단
B03	`search_departments`	JASC/ATA·질의에 맞는 부서 후보. 단계별 준비 및 판단 부서와 ATA 대응 검증
R01	`search_jasc_codes`	질의·코드로 JASC 후보와 정의 조회. LLM2·3 사용 가능
R02	`search_sdr_cases`	explore: 단어 순위 + 벡터 검색을 RRF(k=60)로 결합. exact: 구절 조회. LLM2·3 사용 가능
R03	`search_amm_references`	AMM 번호 정확 조회만 지원. 의미검색 제거, LLM2·3의 도구 선택 목록에서 제외
R04	`search_technical_docs`	Airbus 기술자료 검색 구현. LLM2·3 사용 가능하나 판단에 필수이면 적용성 검토를 위해 보류
R05	`get_evidence`	EV-SDR·EV-AMM·EV-DOC 원문과 범위 재확인. LLM2·3 및 실행기 최종 검증
확장	`get_sdr_amm_references`	최종 실행기가 인용 SDR의 AMM 번호·맥락을 reference_amm으로 첨부. LLM의 판단 도구가 아님

서버와 검색 방식

business-mcp(8101)와 rag-mcp(8102)는 FastMCP의 streamable HTTP를 사용한다. 공통 인증·응답 형식·읽기 전용 트랜잭션·health 경로를 제공한다. business는 mro_business_reader로 업무 뷰와 이력·부서를, rag는 mro_reader로 RAG 테이블을 조회한다. 공개 도구는 9개이며 모든 도구가 읽기 전용이다.

R02는 단어·벡터 후보를 각각 최대 50건으로 고정한 뒤 합친 순위로 페이지를 나눈다. 페이지마다 후보 집합을 키우던 중복 문제를 막는다. R02·R04 임베딩은 OpenAI text-embedding-3-large 1024차원이다. R02는 질의 인코더 미설정, 릴리스의 SDR 벡터 미준비 또는 임베딩 API 실패 시 경고와 함께 단어 검색으로 대체한다. 고정된 단어검색 색인 자체가 없거나 비정상이면 오류를 반환한다. 한국어 벡터 질의가 가능하지만 단어 검색은 영어 중심이다.

위임 인증과 검색 범위

1. Spring이 run_id와 rag_request_contexts를 만들고 데이터 release/index, 모델 범위, 만료 시각을 고정한다. request_version과 context_version은 서로 다른 버전이다.
2. 서버별 위임 토큰(HS256, aud mro-business·mro-rag, 10분)을 RabbitMQ의 x-mro-business-token·x-mro-rag-token 헤더로 전달한다. 토큰은 모델·체크포인트에 저장하지 않는다.
3. 모든 MCP는 위임 토큰과 요청 ID를 검증한다. B01은 실행 뷰의 활성·만료·context_version을, rag-mcp는 실행 컨텍스트와 고정 릴리스·검색 색인을 추가 검증한다. B02·B03은 입력 context_version을 토큰 값과 대조한다. B01은 agent_request_context·agent_run_context 뷰를 사용하며 V9에서 repair_requests 직접 열 권한을 회수했다.
4. 현재 시연은 운항사 NULL의 모델 기반 범위다. context_version=2, 정책 airbus-model-scope-v1이며 mapping_revision=backend-v1-model-only와 구분한다. 국내 항공사를 원본 SDR 운항사로 임의 변환하지 않는다.

R02의 기본 MODEL_GENERATION은 같은 기본 모델과 ceo/neo 세대 안에서 검색한다. 초기 검색이 부족하면 이유를 남겨 FAMILY로 넓힐 수 있다. EXACT는 정확한 세부 모델이며, 미확인 모델·이전 NULL 범위는 EXACT만 허용한다. Backend가 허용한 모델 목록은 단어·벡터 검색과 R05에 함께 적용된다. 검색 범위 확장이 정비 구성의 동일성을 뜻하지 않으므로 LLM3가 구성 차이를 검토한다.

근거 ID와 검증

출처	AI 발행 전	Spring 배정 직전
HISTORY · MH-*	B02로 재확인. LLM1 연결 이력 외에도 LLM3가 조회한 이력을 검토할 수 있음. LLM2 인용 금지	요청과 이력의 기체 모델 일치 확인
SDR · EV-SDR-*	R05 원문·범위·인용 대조, 같은 evidence_group_id를 묶어 전달하고 중복 근거로 세지 않도록 지시	READY release, 활성·미만료 컨텍스트, 데이터 버전·운항사·허용 모델·고정 JASC/날짜 조건 확인
AMM · EV-AMM-*	판단 근거에서 제외. reference_amm에 번호·SDR ID·맥락을 별도로 전달	판단 evidence로 제출하면 거부
DOC · EV-DOC-*	기술자료 원문 확인. 결론에 필수이면 적용성 확인을 위해 보류	ID 존재 확인. 기술 적용성을 보증하지 않음

조회하지 않은 ID는 근거로 인정하지 않는다. 실제 조회한 근거의 발췌를 모델이 의역하면 원문으로 정정한다. AI 검증 또는 Backend 최종 검증에 실패하면 VALIDATION_FAILED로 사람 검토에 넘긴다. DB의 존재·범위 검사는 증상 관련성이나 정비 적용성의 독립 검증과 구분한다.

오류와 예외 처리

OK·NO_DATA·NO_MATCH·NEEDS_INPUT·ERROR와 오류 코드, retryable을 반환한다. MCP SQL 문장은 8초, AI 도구 호출은 10초이며 재시도 가능한 오류에만 1회 재시도한다. rag-mcp 커서는 서명·만료·실행 컨텍스트를 검사한다. B02 커서는 요청·필터 일치를 확인한다. 복구하지 못한 AI 예외는 FAILED로 발행하고 Spring이 SYSTEM_ERROR로 처리한다.

4.3 Harness

구성 요소	강의 최소 기준	우리 구현	판정
Instructions	역할·도구 규칙·금지 사항·출력 형식을 파일로 관리	`app/agent/classification.py`(LLM1), `app/agent/prompts.py`(LLM2·3)의 프롬프트에 역할·도구 규칙·결론/보류 조건·주입 방어 지침, 엄격한 Pydantic 출력. 프롬프트는 코드 상수로 git 관리. MCP 도구 설명에 검색 요령 명시	일부 (md 파일 아님)
Tools	결과 길이 제한, 오류는 ToolMessage	허용 목록, JSON 스키마 입력 검증, 서버 소유 인자 차단, 확인 안 된 JASC 힌트 제외, 10초 제한·1회 재시도. 도구 메시지는 상태·범위·ID로 축약하고 조회 근거는 노드별 컨텍스트로 전달	구현
Context	Token 예산, 넘으면 요약	증상 2,000자·근거 원문 1,500자(인용 300자) 제한, LLM1은 ATA 후보에 해당하는 조회 이력, LLM3는 인용 이력과 추가 이력 최대 20건으로 축약(추가 조회 우선). LLM2는 이력·분류·검토문을 제외한 전용 상태 (158K 토큰 초과 문제를 해결)	축약 구현, Token 집계 없음
State·Memory	thread 단위 저장, 재개	요청 단위 체크포인트, 이벤트 저널로 최종 이벤트 재발행	구현
Agent Loop	최대 8턴, 120초, 같은 도구 3회	노드당 AI 선택 도구 8회, 같은 도구·같은 인자 반복 차단, 재조사 2회, 재귀 80, 실행 280초(모델 45초, 도구 10초), Spring 5분 시간 초과	구현
Guardrails	변경 도구 interrupt, 개인정보 마스킹	MCP에 쓰기 도구 없음, 배정은 Spring이 검증 후 실행. 위임 토큰·요청 ID 검사, 근거 원문 대조, 근거 없는 결론 반려, 토큰은 프롬프트·체크포인트에 남기지 않음, 신고자 식별 컬럼 비공개	구현
Recovery	429·503 2회 재시도, 대체 모델 또는 FAILED	도구는 재시도 가능 오류만 1회. 모델 출력 형식 오류는 오류 내용을 알려 1회 재요청. 대체 모델 없음, 실패 시 FAILED. 큐는 결과 확인 후 ack, 거부는 DLQ	일부 (대체 모델 없음)
Observability	trace id 하나로 Node·도구·Token·지연	Spring 이벤트·단계 결과와 trace API, AI 측 도구 호출 기록, MCP 응답 trace_id·소요 시간 로그	LangSmith·Token 집계 없음

Harness 동작 증빙

검사	관찰 결과와 해석
LLM2 입력 격리	10/23 요청 200건의 체크포인트 종료 확인. InvestigatorState로 투영한 입력 경계 176개에서 HISTORY·B02 0건. 별도 네트워크 프롬프트 캡처는 아니며 격리 회귀 테스트와 함께 해석
재조사·보류	200건에서 RETRY_LIMIT 31, VALIDATION_FAILED 11, AGENT_NEEDS_HUMAN 13. SYSTEM_ERROR 0. 보류 55건 모두의 적절성이 검증된 것은 아님
최종 근거 확인	29건의 조사 경로 배정에서 실행기 R05 trace 97회, SDR→AMM 29회. 조회 사실은 근거 내용의 정확도를 보증하지 않음
과거 실행 기록	4.1의 S10 반려·검색·재확인은 10/21 자료. 현재 성능 수치와 합산하지 않음

쓰기 MCP가 없으므로 변경 도구 interrupt 대신 Spring이 근거·부서를 검증하고 배정을 수행한다. 코드에 검증 장치가 있다는 사실과 실제 평가에서 잘못된 배정을 충분히 차단했다는 주장은 구분한다.

4.4 인증과 권한

- 로그인은 JWT access token 하나(HMAC 서명, 유효 8시간)를 쓴다. 요청마다 사용자를 DB에서 다시 읽어 비활성 계정은 막는다. 비밀번호는 BCrypt로 저장한다.
- 신고자는 직접 가입한다(소속 항공사 선택, 비밀번호 8~72자, 중복 이메일 409). 정비팀과 어드민 계정은 시드로만 만든다.
- 역할이 맞지 않으면 403, 역할은 맞지만 본인 것이 아니면 404를 돌려 다른 사람 요청의 존재 여부를 숨긴다.

동작	신고자	정비팀	어드민(통제사)
수리 요청 생성	소속 항공사 기체만	불가	불가
요청 조회	본인이 낸 것	본인 부서 배정 건	전체
판단 근거(trace)	불가	본인 부서 배정 건	전체
수락·거절	불가	본인 부서, ASSIGNED일 때	불가
사람 검토·통계	불가	불가	수동 배정·종결, 요약 통계

인증 증빙 (2026-10-21 실제 서버 호출 기록)

```
## 1) 토큰 없이 호출 → 401
$ curl http://localhost:8080/api/v1/me
{"error":{"code":"UNAUTHORIZED","message":"인증이 필요합니다."}}  → HTTP 401

## 2) 신고자가 관리자 API 호출 → 403 (역할 불일치)
$ curl -H 'Authorization: Bearer <reporter1@kal.test>' http://localhost:8080/api/v1/reviews
{"error":{"code":"FORBIDDEN","message":"권한이 없습니다."}}  → HTTP 403

## 3) 같은 항공사의 다른 신고자가 남의 요청 조회 → 404 (존재 여부 숨김)
$ curl -H 'Authorization: Bearer <reporter2@kal.test>' http://localhost:8080/api/v1/requests/7eb721ae-eeb8
-4236-be5c-8d157c46925f
{"error":{"code":"NOT_FOUND","message":"대상을 찾을 수 없습니다."}}  → HTTP 404

## 4) 정비팀이 신고 접수 API 호출 → 403
$ curl -X POST -H 'Authorization: Bearer <hyd@mro.test>' http://localhost:8080/api/v1/requests
{"error":{"code":"FORBIDDEN","message":"권한이 없습니다."}}  → HTTP 403

## 5) MCP를 토큰 없이 호출 → 401
$ curl -X POST http://127.0.0.1:8101/mcp
{"error":"unauthorized"}  → HTTP 401

## 6) 비밀번호 오류 → 401 INVALID_CREDENTIALS
{"error":{"code":"INVALID_CREDENTIALS","message":"이메일 또는 비밀번호가 올바르지 않습니다."}}  → HTTP 401
```

4.5 대기열 (RabbitMQ · DLQ)

큐	방향	처리와 실패
`mro.agent.run`	Spring → AI 서버	TTL 5분. 거부되거나 만료되면 `mro.agent.run.dlq`로 이동하고 Spring이 사람 검토(SYSTEM_ERROR)로 바꿈
`mro.agent.events`	AI 서버 → Spring	처리 실패 시 최대 3회(1초부터 3배씩) 재시도 후 `mro.agent.events.dlq`. 형식 오류·없는 요청은 바로 DLQ

Spring은 발행 때 브로커 확인을 기다리고, AI 서버는 prefetch 1로 받아 최종 이벤트 발행이 확인된 뒤에만 ack한다. 처리 중 종료되면 메시지가 다시 전달된다. Spring은 30초마다 5분 넘게 진행 중인 요청을 찾아 사람 검토로 바꾼다.

DLQ 증빙 (2026-10-21): AI 서버를 중지한 상태에서 요청을 접수했다.

```
## 18:04:02 AI 서버 중지 후 상태
mro.agent.run messages= 0 published= 138
mro.agent.run.dlq messages= 0 published= 0
## 18:04:02 요청 접수 22d2bbfc-7ac7-495c-932e-8bccff0857e6
mro.agent.run messages= 0 published= 138
## 18:09:02 요청 상태: HUMAN_REVIEW
mro.agent.run messages= 1 published= 139
mro.agent.run.dlq messages= 0 published= 0
   09:04:02 None → QUEUED  USER 접수
   09:09:02 QUEUED → HUMAN_REVIEW SYSTEM_ERROR SYSTEM AI 실행 요청이 DLQ로 이동 (처리 시간 안에 AI 서버가 가져가지 않음)
RID=22d2bbfc-7ac7-495c-932e-8bccff0857e6
```

5. API 및 End-to-End 테스트 결과

5.1 API

Spring REST 경로는 /api/v1 기준이다. 공개 health는 /actuator/health, MCP·AI health는 각 서버의 루트 경로다.

대상	메서드와 경로 (Spring REST는 `/api/v1` 기준)
공개	`POST /auth/login`, `POST /auth/signup`, `GET /airlines`, Swagger, `GET /actuator/health`(루트)
로그인 사용자	`GET /me`, `GET /departments`, `GET /requests`(mine·status·department·기간 필터), `GET /requests/{id}`
신고자	`POST /requests` (202 접수, 422 보완 안내)
정비팀	`GET /assignments`, `POST /assignments/{id}/accept`, `POST /assignments/{id}/reject`(사유 필수)
정비팀·어드민	`GET /requests/{id}/trace` (단계별 판단, 상태 이력)
어드민	`GET /reviews`, `POST /reviews/{id}/resolve`(ASSIGN·CLOSE), `GET /stats/summary`, `GET /staffing` (인원 현황)
서버 간	MCP `POST /mcp`(8101·8102, 위임 토큰 필수), 상태 확인 `/health`·`/health/ready`·`/health/live`, AI 서버 `/health/live`·`/health/ready`(8100)

Spring REST 오류 응답은 같은 형식(`{"error": {"code", "message", "details"}}`)을 쓴다. `/internal/**`은 막혀 있다.

5.2 자동화 테스트

2026-10-26 확인한 각 main 커밋의 GitHub Actions 결과다. 기존 로컬 테스트 수와 현재 CI 결과를 합산하지 않는다.

저장소 · 커밋	결과	범위와 제한
LLM · e5d3798	186 passed · Ruff 통과	분류·격리·검토·큐 처리·평가 도구 회귀 검사. test_mcp_transport는 ScriptedDemoModel·별도 FastMCP 합성 응답을 사용하므로 실제 모델·agent 서버 호환성 검증과 구분
agent · a30c900	일반 46 passed · 1 skipped business DB 17 passed	별도 Flyway/Postgres CI 작업에서 실제 business-mcp DB 연결 확인. 합성 RAG 데이터 검사는 계약·범위·커서 검사이며 실제 검색 정확도 평가가 아님. 두 작업을 고유 테스트 수로 합산하지 않음
backend · ff47ad5	평가 도구 7 tests · Gradle test 성공	업무·권한·검증·큐 테스트와 오프라인 평가 도구. Java 테스트의 정확한 총 통과 수는 이 표에서 주장하지 않음
dashboard · 99f25f1	vue-tsc · Vite build 성공	타입 검사와 빌드. 브라우저 화면 조작 테스트의 통과를 뜻하지 않음

5.3 서비스 평가 200건과 결과

현재 서비스 평가셋은 backend의 `data/eval/service/scenarios.jsonl`이다. dev 80건·test 120건(A 64 / B 96 / C 16 / D 24), 배정 기대 197건·사람 검토 기대 3건이다. 10/23 격리 수정 후 smoke 4건과 후속 196건을 합쳤고, 격리 전 실행은 제외했다. 모델은 gpt-5.4-mini이며 Backend → RabbitMQ → AI → 실제 HTTP MCP → Docker Postgres 경로로 실행했다.

배정 기대 사례는 ASSIGNED·허용 부서 일치·금지 이력 미인용을 모두 만족해야 통과한다. 사람 검토 기대 사례는 HUMAN_REVIEW 종료가 통과다. 아래 수치는 공개된 summary.json에서 자동 반영한다.

지표	결과
전체 평가 통과	97/200 (48.5%)
자동배정 중 평가 통과	96/145 (66.21%)
배정 기대 사례의 통과	96/197 (48.73%)
사람 검토 기대 사례의 보류	1/3 (33.33%)
최종 사람 검토	55/200
보류 사유	RETRY_LIMIT 31 · VALIDATION_FAILED 11 · AGENT_NEEDS_HUMAN 13
LLM2 마지막 부서 일치 (배정 기대·출력 존재)	71/82 (86.59%)
LLM2 부서는 일치했으나 최종 보류	42건 · 통과에 미합산
평균 / 중앙값 / P95	21.94초 / 10.05초 / 60.4초
접수 실패·타임아웃 / SYSTEM_ERROR	0 / 0
접수 검증 (별도 실행)	6/6 (100.0%)

경로	사례	통과 자동배정	실패 자동배정	사람 검토
LLM1 직접	116	67	49	0
LLM2·3 조사·검토	84	29	0	55

실패 자동배정과 보류

실패 자동배정 49건은 모두 LLM1 직접 경로에서 발생했다. 부서 불일치 11건, 부서는 맞지만 금지 이력 인용 36건, 사람 검토 기대인데 배정한 2건이다. 금지 이력 인용 전체는 37건이며 부서 불일치와 1건 겹친다. 따라서 49건을 모두 부서 오답으로 해석하지 않는다.

LLM2 마지막 출력은 83건이다. 사람 검토 기대 1건을 제외한 82건 중 부서 일치는 71건(86.59%)이며, 그중 최종 보류 42건은 성공에 합산하지 않는다. LLM2·3 경로 자동배정 29건의 평가 실패는 0건이지만, 이 표본만으로 실제 운영 안전성을 확정할 수 없다.

MCP 사용 관찰

노드	도구별 trace 수
classify	B01 200 · B03 200 · B02 226
direct	B01 116 · B03 116 · B02 119
investigate	B01 84 · B03 176 · R01 77 · R02 84
review	B03 174
finalize	B01 29 · B03 29 · R05 97 · SDR→AMM 29

숫자는 체크포인트의 노드별 trace 증가분이다. HTTP 요청·재시도 횟수나 검색 정확도가 아니다. DUPLICATE_CALL 1건은 내부 중복 차단이며 MCP 호출에서 제외했다. 이 실행에서 R03·R04는 0회였지만 R04는 구현되어 있다. AMM은 LLM 판단 후 실행기가 참고자료로 조회한다.

검증 범위와 과거 자료

- 팀 라벨 검토 상태: 미검토 161, 최종 검토 필요 24, 결정 완료 15. dev 통과 38/80, test 59/120이며 무작위 독립 검증이나 동일 조건의 개선 전후 비교를 주장하지 않는다.

- 현재 지표는 기존 1회 실행을 재집계한 결과다. Backend 온라인 의존성 다운로드 실패로 로컬 Gradle 캐시에서 빌드한 JAR을 사용했으므로 깨끗한 환경의 온라인 Docker 빌드 검증은 아니다.
- 프런트 health 확인은 있으나 브라우저 조작 E2E나 AWS 배포 검증은 아니다. LLM2 입력 경계는 부모 상태의 필드 투영 검사이며 프롬프트 네트워크 캡처와 구분한다.
- 10/21의 구 시나리오 23건은 당시 서비스 흐름 기록으로 보존한다(자동배정 21/23, 모호한 증상 제외 기대 부서 일치 14/18, 평균 14.6초). 현재 대표 성능과 합산하지 않으며 raw/·v1/을 변경하지 않았다.

원자료: evaluations/2026-10-23-isolated-200. 입력·시드·실행 파일 해시는 manifest와 freeze에 보존한다. freeze의 AI 기준 커밋만으로 수정 후 실행을 재현할 수 없으며, 실행 파일 34개 해시를 함께 사용해야 한다.

5.4 재집계와 시연

평가 수치는 DB·API 호출 없이 공개 번들에서 재집계할 수 있다. LLM·backend·deliverables 저장소를 같은 상위 폴더에 두고 LLM 루트에서 실행한다.

```
python3 scripts/evaluation/summarize_full_eval.py \
  --bundle ../deliverables/evaluations/2026-10-23-isolated-200 \
  --dataset ../backend/data/eval/service/scenarios.jsonl --check
```

실구동은 integration의 고정 서비스 커밋과 실행 문서를 따른다. Backend가 DB·큐·스키마·시드·RAG 복원을 준비하고, AI_MODE=rabbit으로 AI와 두 MCP를 연결한다. API 키·위임 토큰 비밀값·DB 비밀번호는 저장소에 넣지 않는다.

1. 신고자 접수 → LLM1 이력 비교 → 직접 배정 또는 독립 조사·검토 진행을 확인한다.
2. 정비팀·관리자 화면에서 판단 근거와 별도의 참고 AMM을 확인한다.
3. 정비팀 거절 → 사람 검토 → 관리자 수동 배정·종결을 확인한다.
4. 관리자 인원 현황에서 총원·현재 근무·배정 가능 인원을 확인한다. 해당 수치는 아직 자동 배정에 사용하지 않는다.

위 순서는 현재 기능을 확인할 시연 절차이며 이번 문서 개정에서 실제로 재실행한 결과는 아니다. 과거 S10·S23 시연 기록은 raw/에 남겨 두었다.

6. 주요 문제와 해결 방법, 미완성 기능 및 한계

6.1 주요 문제와 해결 방법

문제	현재 반영과 검증
LLM2가 LLM1 판단·이력에 의존	InvestigatorState·llm2_context로 격리, B02·HISTORY 차단, 검토 단계에서만 병합. 200건·입력 경계 176개 감사와 회귀 테스트
LLM1의 단어 중심 이력 연결	현재·이력의 별도 인용, 대상·현상 관계, 부정 표현·충돌 검증으로 보강. 직접 배정 실패 49건이 남아 의미 판단의 충분성은 추가 개선 필요
검색 순위·페이지 중복	SDR 단어·벡터 RRF와 고정 후보 창으로 페이지네이션. 모델 세대 기본 검색과 사유 있는 FAMILY 확장을 함께 적용
AMM을 판단 근거로 오용	R03을 LLM 선택에서 제외, 최종 SDR에 연결된 reference_amm을 후첨부. Backend는 AMM 판단 근거 거부
business-mcp 권한·실행 범위	V6 직접 열 권한 대신 V9 요청·실행 뷰 사용. 실제 Flyway DB 연결 CI 작업을 분리해 확인
rag-mcp 빌드가 과도하게 무거움	과거 CPU PyTorch 전환을 거쳐 현재 런타임은 로컬 모델·Torch 없이 OpenAI 임베딩 사용. 과거 2.03GB·57초를 현재 이미지 실측값으로 재사용하지 않음
실패 원인 추적·통합 상태 확인	AI는 비밀 메시지 대신 예외 종류·코드 위치·요청 ID를 안전 로그로 기록. 통합 실행 스크립트는 준비·health 실패를 오류로 종료
공유 데이터 소유권	Backend Flyway·복원 스크립트로 일원화. MCP는 조회만, 데이터 제작 결과는 버전·해시가 있는 덤프로 전달

10/21 문제 20건의 상세 기록은 트러블슈팅.md에 그대로 보존하고, 10/26 후속 상태를 별도 절로 추가했다. 과거 표본에서 해소된 현상을 전체 데이터에서 해결된 것으로 일반화하지 않는다.

6.2 남은 개선 과제

우선 과제	근거와 다음 확인
LLM1 직접 배정의 근거 적합성	실패 49건 중 부서는 맞으나 금지 이력인 36건이 핵심. 이력 인용의 의미 관계·충돌 검증을 정답 라벨 검토와 분리해 강화
보류의 적절성과 자동화 범위	LLM2 부서는 맞지만 보류한 42건을 사유별 검토. 계통·구성 충돌이 남는다면 사람 검토가 적절할 수 있어 단순 자동 배정률 목표로 풀지 않음
평가 라벨과 반복 검증	161건 미검토·24건 최종 검토 필요. 전문가 검토, 반복 실행, 독립 평가셋, 검색 관련성 평가를 별도로 수행
기술자료의 정비 적용성	R04 구현 완료와 실제 사용 효과는 별개. 200건에서는 미사용. DOC의 ID 존재만으로 결론에 쓰지 않으며 필수 근거이면 사람 검토
운영 관측·확장	Token 사용량 집계·대체 모델·LangSmith 미적용. 다중 워커와 체크포인트 동시성은 별도 운영 검증 필요
인원 현황의 활용	현재 38명·8부서 조회 화면만 제공. 부서 자동배정에 인원·가용성 미반영, 개인 작업 배정 없음

6.3 해석의 한계

한계	보고서에서의 처리
목업 데이터와 팀 기대 라벨	200건은 서비스 평가다. 실제 정비 진단 정확도·안전 인증이나 운영 성능으로 확대하지 않음
근거 검증의 범위	Backend는 ID·버전·범위를 검사한다. 증상 관련성과 구성 적용성은 AI·사람 검토에 의존
검색과 외부 API	한국어 벡터 검색과 영어 단어 검색을 결합. 임베딩 API 실패 시 단어 검색 경고를 확인해야 하며 검색 성능은 별도 정답 근거로 평가 필요
AMM 원문 부재	SDR의 번호·맥락만 제공한다. 정식 매뉴얼 절차·최신 개정·적용성은 확인하지 않음
화면과 실행 환경	현재 문서 작업 시 Docker·앱 서버가 꺼져 최신 화면을 재촬영하지 못함. 기존 화면은 10/21 기록으로 표시
서로 다른 검증 층	합성 기능 테스트, 실제 HTTP 서비스 평가, 브라우저 시연, AWS 운영 검증을 혼합하지 않음

6.4 기준 버전과 출처

대상	기준·출처
LLM	e5d379828e38200f77f5e3a6641c6ccc77dc1424
backend	ff47ad56c191e14f59bafb7075659ac0935ef008
agent	a30c900c6d3bc0ff8eda83ef3d4876a8679126ac
dashboard	99f25f1cb25615279c6e7aa65f864ea0b3934fe1
integration	ebbc10e55a05cc037a033be351c97261b9d7ed1e

구현 설명은 위 커밋의 코드·Flyway·화면 소스를 기준으로 대조했다. 200건 평가 자료는 기존 실행의 원본과 공개 메타데이터·체크섬을 유지했다. 현재 AI 파일 34개가 평가 당시 해시와 일치함을 확인했으나, 모든 컨테이너·DB 상태를 현재 커밋으로 재실행했다는 뜻은 아니다.

문서 생성: final_report.template.html → source/build_report.py → HTML → Chrome PDF. 재촬영 대상은 관리자 콘솔(인원 현황 진입), /admin/staffing, 판단 근거·참고 AMM 분리 상세 화면이다. 원본 raw/·v1/·기존 화면·평가 번들 및 AWS architecture/는 보존했다.